

Raport WdAD

Maria Pieczarka, Michał Stadnik, Paweł Trojan, Michał Warmuz

Styczeń 2026

1 Opis danych

Dane zostały pobrane z 28627 artykułów z anglojęzycznej Wikipedii, do których na stornie przydzielony został temat matematyka, fizyka lub historia (lub kilka tematów jednocześnie). Dotyczyły zarówno treści, liczby wizyt, jak i historii edycji. Wśród nich znalazły się zmienne kategoryczne, tekstowe oraz liczbowe. Szczegółowy opis każdej z nich znajduje się poniżej:

- **Zmienne dotyczące tytułu i tekstu artykułu**

- `title` – tytuł artykułu
- `summary` – zawartość (treść lub streszczenie) artykułu
- `word_count` – liczba słów w artykule (oraz `log_word_count`)

- **Zmienne dotyczące obrazów**

- `num_images` – liczba obrazów w artykule (oraz `log_num_images`)
- `image_titles` / `image_titles_string` – tytuły/podpisy obrazów

- **Statystyki wizyt i zaangażowania**

- `mo_page_views` – miesięczna liczba wyświetleń strony (oraz `log_...` i flaga `is_..._zero`)
- `clicks_in` – liczba wejść na stronę z linków wewnętrznych (oraz `log_...` i flaga `is_..._zero`)
- `clicks_out` – liczba kliknięć w linki wychodzące na stronie (oraz `log_...` i flaga `is_..._zero`)
- `clicks_per_view` – współczynnik zaangażowania (oraz `log_...` i flaga `is_..._zero`)

- **Statystyki struktury i historii edycji**

- `num_links_internal` – liczba linków wewnętrznych w artykule (oraz `log_...`)
- `num_editors` – liczba unikalnych edytorów (oraz `log_...`)
- `num_edits` – całkowita liczba edycji (oraz `log_...`)
- `creation_date_timestamp` – data utworzenia jako znacznik czasu (oraz `log_...`)

– `links_per_word` – gęstość linków (liczba linków na słowo, oraz `log...`)

- **Kategorie i typologia**

- `type` – dziedzina artykułu (Mathematics, Physics, History)
- `num_categories` – liczba kategorii, do których należy artykuł (oraz `log...`)
- `categories` / `categories_string` – lista przypisanych kategorii
- **Indykatory kategorii** – zmienne binarne (0/1) wskazujące na przynależność do specyficznych, popularnych kategorii, m.in.: `cat_mathematics_related_lists`, `cat_quantum_mechanics`, `cat_living_people`, `cat_historiography`, `cat_fellows_of_the_american_mathematical_society` i inne (łącznie 28 wybranych kategorii).

2 Tematy analizy

W projekcie skupiliśmy się na czterech problemach, do każdego z nich zastosowaliśmy inną, naszym zdaniem najlepiej pasującą, metodę uczenia maszynowego. Celem tego było wykorzystanie pełni potencjału i pokazanie wszechstronności różnych metod wraz z przedstawieniem przykładów, do których nadają się one najlepiej.

2.1 Klasyfikacja kategorii artykułów

W tej części skupiliśmy się na zbadaniu sposobu, w jaki Wikipedia przydziela kategorie poszczególnym artykułom w zależności od treści oraz tytułu. Stąd ze zbioru danych wybraliśmy dwa parametry – "summary" (czyli treść artykułu) oraz "title" (czyli tytuł). Warto zwrócić uwagę, że są to dwie najlepiej widoczne dla użytkowników kategorie, co pozwala zastosować nasz model nawet w przypadku, gdy nieznane są informacje dotyczące np. liczby edycji, do której często nie mamy dostępu.

Naiwny klasyfikator bayesowski wydał się być zdecydowanie najlepszą metodą uczenia maszynowego do tego problemu – jest to metoda uczenia nadzorowanego (co jest w naszym przypadku konieczne) oraz szczególnie dobrze działa w przypadku wielu klas kategoriycznych. Z tego powodu jest to bardzo dobra metoda dla klasyfikatorów tekstowych.

Implementacja metody wymagała wstępnego przetworzenia danych. Z treści artykułów usunięte zostały znaki interpunkcyjne, liczby, spójniki oraz często występujące znaki końca linii "\n". Ponadto wszystkie wielkie litery zostały zamienione na małe oraz użyta została funkcja "`tm_map(stemDocument)`", która usunęła końcówki wyrazów, żeby skupić się na ich znaczeniu.

Ze względu na duże zużycie pamięci konieczne było przejście na macierze rzadkie. Pełne macierze momentami ważyły ponad gigabajt, co uniemożliwiało pracę z nimi. Ponadto ograniczyliśmy się tylko do słów występujących w co najmniej 50 treściach artykułów lub 5 tytułach.

Ponieważ zbiór danych był uporządkowany, zbiór testowy został wybrany jako próba losowa z całego zbioru danych. Na jego utworzenie wykorzystane zostało 5000 obserwacji z ponad 28000.

W metodzie wykorzystany został naiwny klasyfikator bayesowski w dwóch wersjach – standardowej oraz z wygładzeniem laplace o wartości 1. W wynikach końcowych liczonych

za pomocą dokładności (co wydaje się w tym przypadku być najlepszą miarą, ponieważ żadna obserwacja nie jest w naszym problemie ważniejsza niż jakakolwiek inna) lepszy okazał się ten bez wygładzenia. Ich dokładności wynosiły odpowiednio 65% oraz 63,42%. Oba te wyniki wydają się być całkiem dobre, szczególnie, że do przewidywania były aż trzy duże klasy i trzy bardzo małe, więc widać znacząco lepszy wynik niż przydzielanie wyników w sposób losowy. Szczególnie trzeba mieć w tym przypadku na uwadze fakt, że przydział kategorii może być kwestią subiektywną, a granica między artykułem z dziedziny matematyki a fizyki może niekiedy być bardzo cienka. Stąd tym bardziej zrozumiałe jest występowanie problemów związanych z błędną klasyfikacją.

2.2 Estymacja współczynnika zaangażowania artykułu przy użyciu drzew decyzyjnych

W tej sekcji opiszemy próbę zbudowania modelu który będzie przewidywał współczynnik zaangażowania artykułu, na podstawie informacji o jego budowie oraz historii edycji.

Współczynnik zaangażowania definiujemy jako:

$$\text{Współczynnik zaangażowania} = \begin{cases} \frac{\text{Liczba kliknięć w link na stronie}}{\text{Liczba wyświetleń strony}} & \text{gdy Liczba wyświetleń} > 0 \\ 0 & \text{gdy Liczba wyświetleń} = 0 \end{cases}$$

Rozumiemy go następująco: jeśli artykuł angażuje ludzi to większość odwiedzających daną stronę kliknie w jakikolwiek link przekierowujący do innej strony na wikipedii. Może to oznaczać, że artykuł jest ciekawy, albo jest zbiorczą listą przydatnych artykułów. Niestety, aby rozróżnić te dwa przypadki potrzebowalibyśmy informacji o czasie przebywania na danej stronie, a nie udało się znaleźć takiej informacji. Z kolei jeśli artykuł nieangażuje ludzi, to większość wyświetleń danego artykułu zakończy się zamknięciem karty, kliknięciem przycisku "wstecz" lub w jakiś inny sposób nie prowadzący do kliknięcia w link na stronie.

Ze względu na to, że w strukturze oraz historii edycji artykułu można by było wyróżnić wiele niuansów wpływających na współczynnik zaangażowania (np. długie artykuły z małą ilością linków mogą pozytywnie wpływać na ów współczynnik, ale także krótkie artykuły z długą listą linków również będą działały pozytywnie na ten współczynnik. Nie wspominając już o potencjalnym wpływie historii edycji albo ilości zdjęć) to postanowiliśmy użyć w tym zadaniu drzew decyzyjnych, które świetnie się sprawdzają w wyłapywaniu wszelkich zależności.

Ze względu na to, iż dość dużo artykułów miało zerowy współczynnik wyświetleń (ok 46%) (było to spowodowane albo zerową liczbą kliknięć w link na stronie, albo zerową liczbą wyświetleń), to postanowiliśmy podejść do tego problemu dwuetapowo. W ramach pierwszego kroku zbudowaliśmy klasyfikacyjne drzewa losowe które decydowały, czy współczynnik zaangażowania wynosi 0 czy też nie. W ramach kolejnego kroku zdecydowaliśmy się zbudować regresyjne drzewa, których zadaniem było oszacowanie współczynnika zaangażowania artykułów o których drzewo w pierwszym kroku powiedziało, że ma niezerowy tenże współczynnik. Dlatego też, drzewa w drugim kroku zostały wytrenowane na danych z których usunięto artykuły o zerowym współczynniku zaangażowania.

Do sprawdzania jakości otrzymanych drzew klasyfikacyjnych użyto tabeli krzyżowej oraz współczynnika "accuracy", tj. współczynnika dobrych trafień do ilości wszystkich danych. Zrobiono tak ze względu, iż obydwa błędy klasyfikacji miały podobne znaczenie.

Z kolei do sprawdzania jakości drzew regresyjnych użyto współczynnika MAE, współczynnika korelacji między danymi rzeczywistymi oraz wyestymowanymi oraz porównywano zakresy otrzymanych predykcji (ze względu na silną skośność współczynnika zaangażowania, predykcje nie pokrywały całego przedziału $[0, 1]$). Analizowano również wykres zależności wartości rzeczywistych i przewidzianych oraz histogramy otrzymanych wyników.

Ze względu na to, iż większość zmiennych miała silnie prawoskośne rozkłady, zaś zlogarytmowanie pozwalało uzyskać symetryczne rozkłady, postanowiliśmy wytrenować różne warianty drzew decyzyjnych: używających danych zlogarytmowanych i niezlogarytmowanych. W przypadku drzew klasyfikacyjnych to podejście raczej nic nie wniesie nowego, ale w przypadku drzew regresyjnych (w szczególności drzew modeli) już może poprawić wynik, jeśli dane zależą w sposób wykładniczy od zmiennych. Otrzymane wyniki przedstawię w tabelach.

Tabela 1: Dokładność modelu klasyfikacyjnego (Accuracy) w zależności od liczby iteracji w algorytmie ADA Boost (Trials)

Liczba Triali	Dokładność (Accuracy)	
	Dane Niezlogarytmowane	Dane Zlogarytmowane
1	0.7875	0.7866
3	0.7896	0.787
5	0.7788	0.7864
10	0.7854	0.7912

Jak widać wszystkie drzewa mają zbliżone accurancy. W tym przypadku warto użyć brzytwy Ockhama, jeśli bardziej skomplikowany model ma taką samą skuteczność jak prostszy, to lepiej użyć tego prostego. A ponieważ model bez logarytmowania jest lepiej interpretowalny, to ostatecznie należy uznać, że najlepsze będzie pojedyncze drzewo losowe bez logarytmowania zmiennych ilościowych.

Tabela 2: Wyniki Drzew regresji (rpart): Porównanie błędu MAE oraz korelacji
a) Średni Błąd Bezwzględny (MAE) b) Współczynnik Korelacji

Wejście		Zmienna Celu	
		Liniowa	Log
Zmienne	Liniowe	0.0924	0.0781
	Log	0.0924	0.0781
Model trywialny		0.0974	0.0838

Wejście		Zmienna Celu	
		Liniowa	Log
Zmienne	Liniowe	0.304	0.335
	Log	0.304	0.335

Pierwsze co należy zauważyć, to totalną niewrażliwość na logarytmowanie danych wejściowych. Znając metodę tworzenia drzew regresji ten rezultat jest jak najbardziej spodziewany. Modele wygenerowały małą liczbę liści (zaledwie 4-6). MAE w obydwu przypadkach jest tylko o 0,5% większe od MAE trywialnego klasyfikatora, przypisującego zawsze średnią. Również korelacja jest niska. Minimalne przewidywane wartości są na poziomie ok 0,1, zaś maksymalne na poziomach ledwie 0.25, co oznacza, że zakres predykcji pokrywa ledwie $\frac{1}{8}$ rzeczywistego przedziału. Podsumowując, drzewa regresyjne nie nadają

się do tych danych (co jest najprawdopodobniej spowodowane dużą skośnością zmiennej objaśnianej). Być może gdyby były one bardziej rozbudowane, rezultaty byłyby lepsze.

Tabela 3: Wyniki Drzew Modeli (Cubist): Porównanie błędu MAE oraz korelacji
a) Średni Błąd Bezwzględny (MAE) b) Współczynnik Korelacji

Wejście		Zmienna Celu	
		Liniowa	Log
Zmienne	Liniowe	0.0840	0.0728
	Log	0.0843	0,0735
Model trywialny		0.0974	0.0838

Wejście		Zmienna Celu	
		Liniowa	Log
Zmienne	Liniowe	0.387	0.391
	Log	0.402	0.399

Drzewa modeli dają lepsze rezultaty niż drzewa regresyjne. MAE jest znacząco niższe, osiągając dla liniowych zmiennych pomocniczych i zlogarytmowanej zmiennej docelowej poziom 0,0728, które jest najlepszym wynikiem spośród wszystkich drzew. Również histogram przewidzianych wartości przypomina rzeczywiste dane. We wszystkich przypadkach, wykres punktowy zależności między zmiennymi przewidzianymi, a rzeczywistymi pokazuje pewną tendencję modelu: ma on skłonność przypisywać artykułom ze stosunkową wysoką wartością przewidywanego współczynnika, dużo niższe wartości, zresztą tak samo dzieje się z artykułami o bardzo niskim współczynniku. Niemniej, zakres przewidywanych wartości jest znacznie szerszy niż dla drzew regresji i sięga do 65\$. Jeśli chodzi o korelację to wciąż są na dość niskim poziomie, niemniej wyższym niż drzewa regresji.

Podsumowując, widać, że logarytmowanie pomaga osiągnąć lepszy model, jednakże w zależności od przyjętej miary różnić się będą wnioski co do tego które drzewo jest najlepsze. Pod względem MAE wygrywają drzewa ze zlogarytmowaną zmienną objaśnianą. Pod względem współczynnika korelacji: minimalnie wygrywa model ze zlogarytmowanym wejściem i liniowym wyjściem, natomiast pod kątem rozpiętości przedziału predykcji najlepszy jest model z liniowym wejściem i zlogarytmowanym wyjściem. Świadczyć to może o zależności wykładniczej między danymi liczbowymi a współczynnikiem zaangażowania. W tym przypadku drzewa modeli poradziły sobie znacząco lepiej niż drzewa regresji.

2.3 Klasyfikacja i regresja poziomu zaangażowania z wykorzystaniem algorytmu K-Nearest Neighbors (KNN)

Kolejną metodą wykorzystaną do analizy naszych danych był algorytm KNN i jego możliwości w zakresie **przewidywania wskaźnika zaangażowania w treść**, definiowanego jako *clicks per view*.


2.3.1 Klasyfikacja KNN

Po pierwsze, ze względu na duży odsetek artykułów, dla których nie zareportowano żadnego zaangażowania, mimo niezerowej liczby linków wewnętrznych [Tab. 4], postanowiliśmy przeprowadzić **klasyfikację** $\log_clicks_per_view = 0$ vs. $\log_clicks_per_view > 0$ (ze względu na to, że logarytmowaliśmy dane przesunięte o 1, jest to równoważne problemowi $clicks_per_view = 0$ vs. $clicks_per_view > 0$).

	clicks per view = 0	clicks per view > 0
liczba artykułów	10439	12463

Tabela 4: Rozkład liczbości klas

Wszystkie wykorzystane cechy zostały **wystandaryzowane** w celu zrównoważenia wpływu cech. Jeżeli zmienna ciągła miała dwie wersje - z logarytmem i bez, do modelu została wybrana ta z rozkładem bliższym normalnemu [Rys. 1].




Rysunek 1: Porównanie rozkładów

Zmienna	Typ
log word count	ciągły
num images	ciągły
num categories	ciągły
log num links internal	ciągły
log num editors	ciągły
num edits	ciągły
creation date timestamp	ciągły
log links per word	ciągły
categories (OHE)	binarny

Tabela 5: Zmienne wybrane do modelu


Odpowiednie k zostało wybrane metodą **cross-validacji** [Rys. 2]. Było ono równe 11 i pozwoliło uzyskać ostateczną **dokładność (accuracy) na poziomie 0.77**.



Rysunek 2: Wyniki cross-walidacji dla klasyfikacji KNN

2.3.2 Regresja KNN

Z wykorzystaniem tych samych zmiennych została wykonana regresja zlogarytmowanego wskaźnika *clicks per view*. Przy użyciu cross-walidacji optymalne k zostało określone jako równe 21. Algorytm pozwolił ostatecznie uzyskać $R^2 = 0.314$, $RMSE = 0.086$ oraz $MAE = 0.056$.




k	RMSE
5	0.08998771
7	0.08819632
9	0.08740525
11	0.08682771
13	0.08642395
15	0.08611523
17	0.08585791
19	0.08581224
21	0.08576875
23	0.08575809
25	0.08574710

Rysunek 3: Wyniki cross-walidacji dla regresji


2.3.3 Two-stage KNN

Przetestowana została również dwuetapowa metoda KNN. Jako pierwszy krok przewidywała ona $\log_clicks_per_view = 0$ vs. $\log_clicks_per_view > 0$ i regresowała dodatnią wartość tylko, jeśli wskaźnik został sklasyfikowany jako niezerowy. Dokładność klasyfikacji była jednak zbyt mała, aby uzyskać satysfakcjonujące rezultaty i nawet po przeprowadzeniu tuningu parametrów k w obu krokach wskaźniki MAE , R^2 i $RMSE$ nie były lepsze niż dla klasycznej regresji KNN.

Predicted vs. fitted



Rysunek 4: Regression KNN



Rysunek 5: Two-stage KNN

2.4 Klasteryzacja artykułów na podstawie tytułu i treści

Ostatnią częścią projektu była próba nienadzorowanej analizy struktury zbioru danych przy użyciu metod klasteryzacji, wykonanej wyłącznie na podstawie informacji tekstowych zawartych w tytule oraz streszczeniu artykułów. Celem tej analizy było sprawdzenie, czy na podstawie samej treści artykułów możliwe jest wyodrębnienie sensownych, tematycznie spójnych grup, które w pewnym stopniu odpowiadałyby kategoriom przypisywanym artykułom przez Wikipedię.

Ze względu na bardzo duże zużycie pamięci operacyjnej przy pracy z danymi tekstowymi, konieczne było znaczące ograniczenie rozmiaru zbioru danych. Ostatecznie analiza została przeprowadzona na losowej próbie 6000 artykułów wybranych z pełnego zbioru danych. Był to optymalny rozmiar próby, dla którego możliwe było wykonanie dalszych obliczeń przy dostępnych zasobach sprzętowych.

Pierwszym krokiem była obróbka tekstu. Zarówno streszczenia artykułów, jak i ich tytuły zostały przekształcone do postaci korpusu tekstowego. W ramach wstępnego przetwarzania usunięto wielkie litery, liczby, znaki interpunkcyjne, słowa funkcyjne (stopwords) oraz znaki nowej linii. Następnie zastosowano stemming, aby sprowadzić wyrazy do ich rdzeni i skupić się na ich znaczeniu, a nie odmianach fleksyjnych. Na końcu usunięto nadmiarowe białe znaki.


Na podstawie przetworzonego korpusu utworzono macierze dokument–słowo osobno dla streszczeń oraz tytułów artykułów. Z uwagi na ogromną liczbę możliwych cech oraz bardzo niską gęstość macierzy, konieczne było przejście na reprezentację w postaci macierzy rzadkich. Dodatkowo ograniczono zbiór cech do słów występujących w co najmniej pięciu dokumentach, co pozwoliło zmniejszyć wymiarowość problemu bez istotnej utraty informacji. Ostateczna macierz cech powstała poprzez połączenie informacji ze streszczeń oraz tytułów, przy czym słowa pochodzące z tytułów zostały odpowiednio oznaczone.

W pierwszym podejściu uruchomiono algorytm klasteryzacji k-średnich dla liczby klastrów $k = 6$, co wydawało się naturalnym wyborem ze względu na liczbę głównych kategorii występujących w danych. Analiza liczości otrzymanych klastrów ujawniła jednak znaczną dysproporcję pomiędzy ich rozmiarami. Co więcej, wielokrotne uruchamianie algorytmu prowadziło do istotnych zmian w składzie najmniej licznego klastra, co sugerowało jego niestabilność i wskazywało na potencjalnie nieoptymalny wybór parametru

k .

W kolejnym kroku podjęto próbę doboru odpowiedniej liczby klastrow przy użyciu metody łokcia. Algorytm k -średnich został uruchomiony dla wartości $k = 2, 3, 4, 5, 6, 7, 8, 9$, a dla każdej z nich obliczono całkowitą wewnątrzklastrową sumę kwadratów odchyleń (WCSS), stanowiącą miarę homogeniczności klastrow. Następnie wartości te zostały przedstawione na wykresie zależności WCSS od liczby klastrow. Analiza wykresu wskazała na wyraźny punkt łokcia dla $k = 4$ lub $k = 5$, co sugerowało, że dalsze zwiększanie liczby klastrow nie prowadzi już do istotnej poprawy jakości podziału. Tym dwóm wartościom poświęcono dalszą analizę.

2	3	4	5	6	7	8	9
1 169 278	1 142 182	1 128 677	1 118 501	1 111 329	1 106 507	1 101 961	1 099 639



Rysunek 6: Homogeniczność

Aby lepiej zrozumieć charakter otrzymanych klastrow, dla każdej z analizowanych konfiguracji wyznaczono zestawy słów najbardziej charakterystycznych dla poszczególnych klastrow. W tym celu obliczono różnicę pomiędzy średnią częstością występowania danego słowa w dokumentach należących do klastra oraz w dokumentach spoza klastra, a następnie wybrano dziesięć słów o największej dodatniej różnicy.

Dla przypadku $k = 4$ uzyskane listy słów pozwalały zarysować tematykę artykułów występujących w danych klastrow. W **K1** dominowały słowa *place*, *major*, *much*, *great*, *made*, *peopl*, *becom*, które odnoszą się do ogólnych pojęć opisujących ludzi i miejsca. **K2** zawierał terminy takie jak *displaystyl*, *result*, *defin*, *valu*, *possibl*, *function*, *will*, sugerujące artykuły o charakterze matematyczno-logiczno-formalnym. W **K3** pojawiały się wyrazy związane z publikacjami i tytułami naukowymi, np. *title_list*, *peerreview*, *postdoctor*, *phd*,

title_physic, wskazujące na kontekst akademicki. **K4** obejmował słowa takie jak *year*, *new*, *time*, *histori*, *nation*, *peopl*, *made*, co sugeruje artykuły o charakterze historycznym i biograficznym.

K1	place	major	much	great	made	peopl	becom
Waga	0.748	0.746	0.740	0.740	0.730	0.719	0.714
K2	displaystyl	result	defin	valu	possibl	function	will
Waga	0.594	0.566	0.551	0.517	0.508	0.505	0.502
K3	title_list	peerreview	postdoctor	phd	title_physic	emeritus	title_(mathematician)
Waga	0.024	0.012	0.011	0.009	0.008	0.007	0.006
K4	year	new	time	histori	nation	peopl	made
Waga	0.531	0.505	0.493	0.461	0.442	0.426	0.422

Dla przypadku $k = 5$ uzyskane listy słów również wskazują na wyraźne różnice tematyczne między klastrami. W **K1** dominowały słowa *possibl*, *result*, *mean*, *even*, *similar*, *allow*, *describ*, sugerujące teksty o charakterze matematycznym lub opisowym. **K2** zawierał terminy takie jak *phd*, *title_list*, *fellow*, *peerreview*, *postdoctor*, *emeritus*, *bachelor*, wskazujące na kontekst akademicki i zawodowy naukowców. W **K3** pojawiały się wyrazy *peopl*, *place*, *great*, *major*, *began*, *led*, *much*, które odnoszą się do osób i działań w historii nauki lub społeczeństwie. **K4** obejmował słowa *displaystyl*, *defin*, *function*, *result*, *number*, *set*, *valu*, co sugeruje artykuły o tematyce matematyczno-formalnej lub technicznej. W **K5** znalazły się wyrazy *year*, *new*, *time*, *histori*, *nation*, *peopl*, *part*, charakterystyczne dla tekstów o historii, społeczeństwie i kontekście kulturowym.

K1	possibl	result	mean	even	similar	allow	describ
Waga	0.685	0.659	0.650	0.649	0.633	0.633	0.628
K2	phd	title_list	fellow	peerreview	postdoctor	emeritus	bachelor
Waga	0.025	0.022	0.017	0.016	0.014	0.010	0.009
K3	peopl	place	great	major	began	led	much
Waga	0.796	0.778	0.763	0.762	0.752	0.745	0.740
K4	displaystyl	defin	function	result	number	set	valu
Waga	0.570	0.439	0.430	0.395	0.386	0.379	0.374
K5	year	new	time	histori	nation	peopl	part
Waga	0.527	0.499	0.492	0.454	0.442	0.433	0.429

Podsumowując, przeprowadzona analiza klasteryzacyjna pokazała, że nawet przy znacznym ograniczeniu zbioru danych oraz przy wykorzystaniu wyłącznie informacji tekstowych, możliwe jest uzyskanie sensownego, interpretowalnego podziału artykułów na grupy tematyczne. Wyniki te potwierdzają, że treść i tytuł artykułu niosą wystarczająco dużo informacji, aby odtworzyć główną strukturę kategorii obecnych w danych.